리눅스 커널 스케줄링

(기본 CFS / NICE 값을 적용한 CFS)를 각각 적용

2021년 11월

차 례

1장 프로젝트 동기/목적

리눅스 커널의 스케줄링 정책을 이해 하고 NICE 값을 조정한 CFS를 확인 할 수 있는 프로그램을 작 성한다. 이를 통해 리눅스 기본 스케줄링 CFS 에 대해 이해한다.

- 기본 CFS 와 nice 값을 조절한 CFS 구현 완료
- 커널 소스 수정을 통한 커널 수정을 통한 RealTime FIFO 스케줄러 구현

첨부한 source 파일은 CFS 2가지 구현을 증명하기 위한 cfs.c 와
make 사용 미숙으로 커널 소스에서 수정했던 /usr/src/linux-5.11.22/kernel/sched/core.c 와
/usr/src/linux-5.11.22/.config 파일을 첨부합니다.

2장 설계/구현

리눅스 커널의 기본 스케줄링 정책인 CFS 에 대해서 알아보자.

기본 개념 :

'CFS'란 n개의 프로세스에게 각각의 일정한 시간을 제공하는 스케쥴링 방법이다.
이 때 우선 순위를 정하기위해 커널은 nice 값을 각각 부여하는데 이 nice 값을 각 process의 비율로 설정한 다. 이 비율을 기준으로 timeslice를 할당 받는 것이다.

NICE 값은 (-19) ~ 20 사이의 값을 가진다.

NICE 값을 유저가 변경할 수 있게 하는 시스템 콜이 존재하는데 nice()가 이에 해당한다.

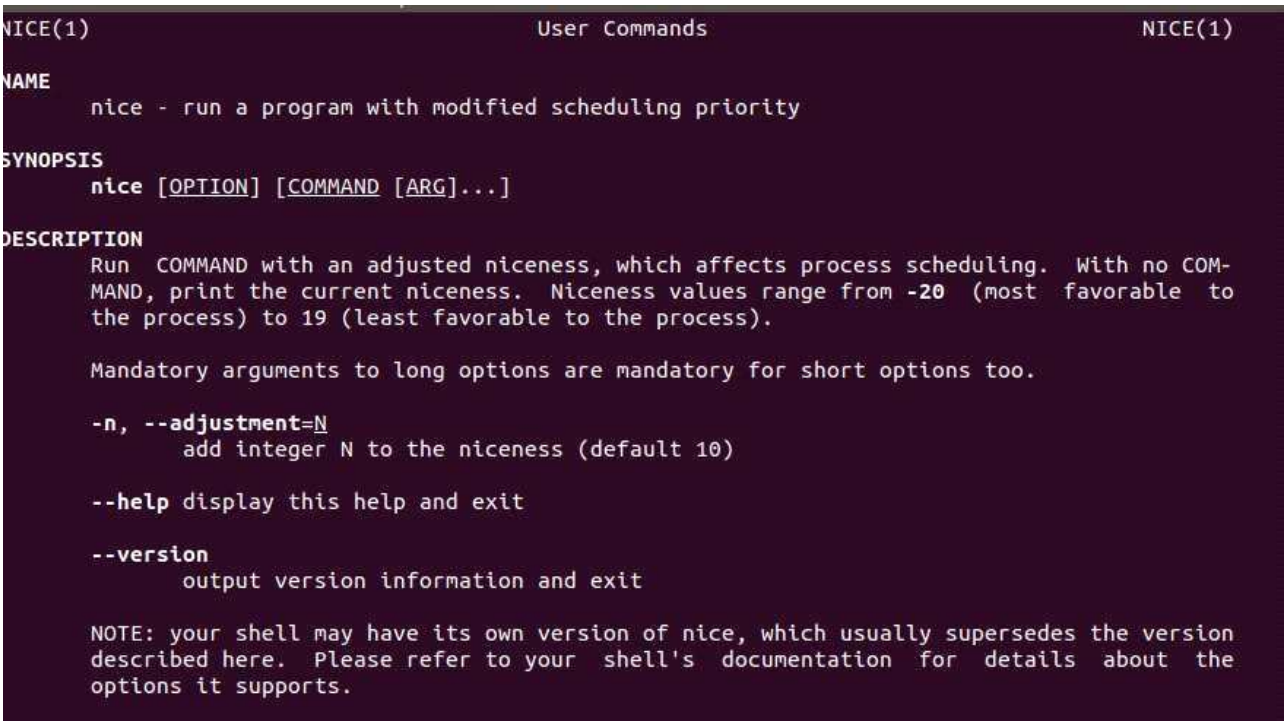

```
NICE(1)                          User Commands                          NICE(1)

NAME
       nice - run a program with modified scheduling priority

SYNOPSIS
       nice [OPTION] [COMMAND [ARG]...]

DESCRIPTION
       Run  COMMAND with an adjusted niceness, which affects process scheduling.  With no COM-
       MAND, print the current niceness.  Niceness values range from -20  (most  favorable  to
       the process) to 19 (least favorable to the process).

       Mandatory arguments to long options are mandatory for short options too.

       -n, --adjustment=N
              add integer N to the niceness (default 10)

       --help display this help and exit

       --version
              output version information and exit

       NOTE: your shell may have its own version of nice, which usually supersedes the version
       described here.  Please refer to your  shell's  documentation  for  details  about  the
       options it supports.
```

사실 nice 값 만들 가지고 운영체제가 수행 순서를 정하지는 않는다. PI 값이 라는 새로운 값이 존재하는데 이는 운영체제가 직접 결정하는 것이므로 바꿀 수 없다. 그래서 운영체제는 변경되는 nice 값을 참고하여 수 행 순서를 정하게 된다.

기본 적인 CFS로 이루어진 스케쥴링 방식은 단순히 21개의 자식 프로세스를 생성하여 작업을 부여하면 간 단히 보여진다.

NICE 값을 변경한 값 은 앞서 설명한 nice() 함수를 이용하여 가장 많은 작업을 하는 프로세스들에는 가장 앞선 우선순위를 가장 적은 작업량의 프로세스들에게는 가장 느린 우선순위를 부여할 것이다. 기존의 CFS 의 결과와 비교해보자.

3장 수행결과

실행전 예측한 결과 :
기존의 CFS 의 경우 CPU사용률이 제일 큰 프로세스 순서의 역순으로 작업이 이루어 질 것이다.
Nice 값을 조정한 CFS 의 경우 새로운 우선 순위 값에 따라 작업량이 제일 크지만 우선순위가 제일 높은 프로세스부터 cpu를 할당 받을 것이다.

결과 :

```
sanghyun@ubuntu:~$ sudo ./a.out
(1) basic CFS , (2) new CFS :1
parent process start!
[hard work] start 12549 ( 0 )
[hard work] start 12550 ( 0 )
[hard work] start 12551 ( 0 )
[hard work] start 12552 ( 0 )
[hard work] start 12553 ( 0 )
[hard work] start 12554 ( 0 )
[hard work] start 12555 ( 0 )
[normal work] start 12558 ( 0 )
[small work] start 12564 ( 0 )
[normal work] start 12560 ( 0 )
[small work] start 12563 ( 0 )
[small work] start 12565 ( 0 )
[normal work] start 12559 ( 0 )
[normal work] start 12557 ( 0 )
[normal work] start 12561 ( 0 )
[normal work] start 12562 ( 0 )
[small work] start 12568 ( 0 )
[small work] start 12566 ( 0 )
[small work] start 12569 ( 0 )
[normal work] start 12556 ( 0 )
[small work] start 12567 ( 0 )
[small work] end 12564 ( 0 )
[small work] end 12565 ( 0 )
[small work] end 12566 ( 0 )
[small work] end 12569 ( 0 )
[small work] end 12568 ( 0 )
[small work] end 12567 ( 0 )
[small work] end 12563 ( 0 )
[normal work] end 12557 ( 0 )
[normal work] end 12562 ( 0 )
[normal work] end 12558 ( 0 )
[normal work] end 12561 ( 0 )
[normal work] end 12559 ( 0 )
[normal work] end 12560 ( 0 )
[normal work] end 12556 ( 0 )
[hard work] end 12553 ( 0 )
[hard work] end 12551 ( 0 )
[hard work] end 12554 ( 0 )
[hard work] end 12555 ( 0 )
[hard work] end 12549 ( 0 )
[hard work] end 12550 ( 0 )
[hard work] end 12552 ( 0 )
parent process ends
sanghyun@ubuntu:~$
```

기본 CFS를 통해 실행해 보았을 때 예상결과와 맞게 결과가 도출 되었다.

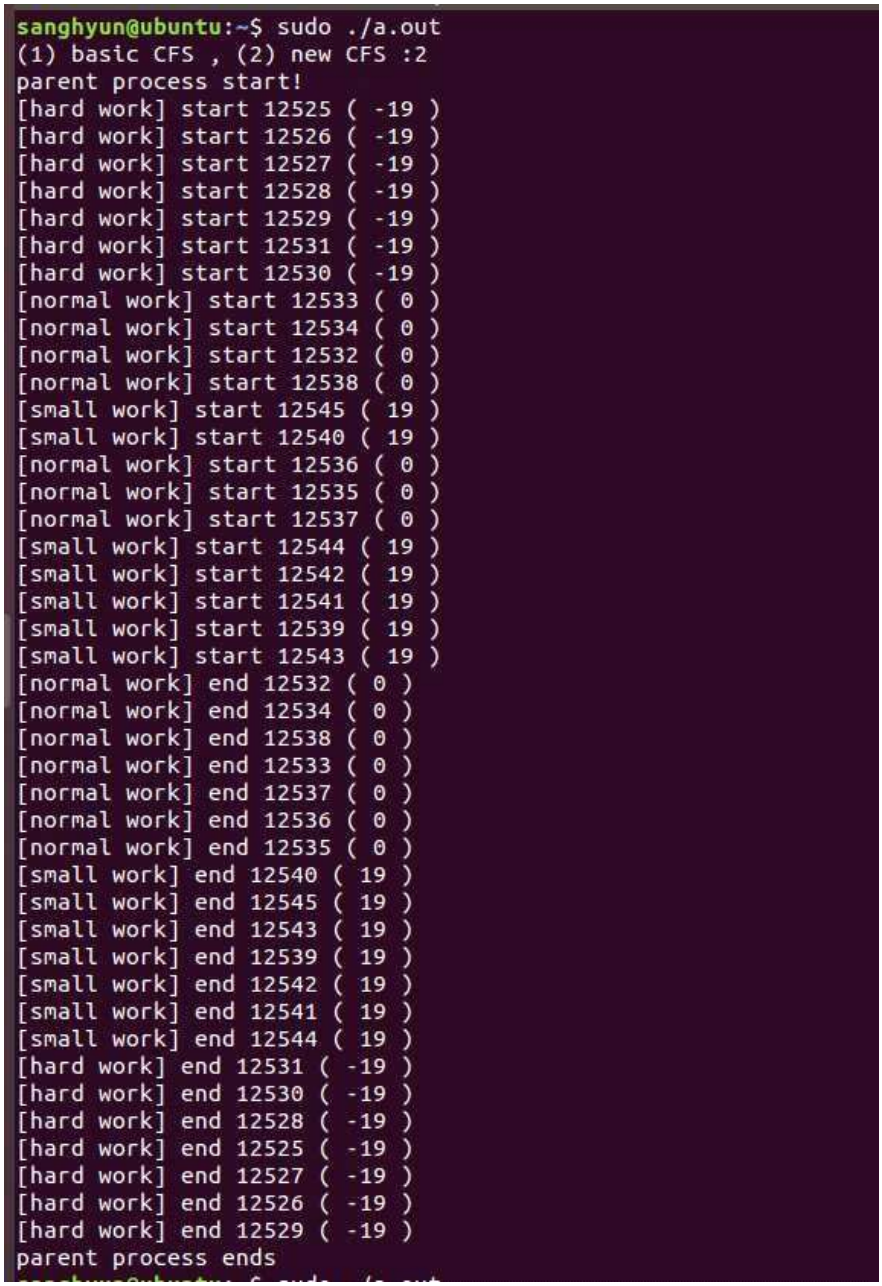

NICE 값을 조정한 CFS 의 경우 예상과는 조금 다르다.
[nomal work / normal NICE] > [small work / big NICE] > [big work / small NICE]
순으로 작업이 완료되었다.
예상 결과 랑은 약간 차이가 있지만 우선순위에 변경에 따른 유의미한 차이를 찾을 수 있었다. 운영체 제는 유저가 주어준 프로세스 간의 우선순위 값은 NICE를 참고하여 CPU를 할당하였고 기본 결과보다 다른 결과가 도출 되었다.

** NICE 값을 기존의 0에서 음수로 줄이기 위해서는 무조건 root 권한으로 실행하여야한다!

* 리눅스 커널 수정을 통한 FIFO 스케줄링

kernel/sched/core.c 소스를 확인해보면 sched_init() 함수를 확인 할 수 있다. 이 함수의 역할은 task_group 구조체인 root_task_group에 CFS 스케줄러 구조체와 RT 스케줄러 구조체 포인터를 할당하는 역할을 한다.

또 CFS 스케줄러와 RT 스케줄러 소스는 컴파일 시점에 선택적 조건으로 컴파일 되는데 커널 소스 컴파일 정의(.config 에 해당한다) 에 CONFIG_FAIR_FGROUP_SCHED 가 정의되어있으 면 CFS 스케줄러 소스가 컴파일 되고 CONFIG_RT_GROUP_SCHED가 정의 도어 있으면 RT 스케줄러 소스가 컴파일 되게 된다.

지금 과제에서 묻는 부분은 현재 default 로 저장되어있는 CFS 스케줄링을 FIFO 스케줄링으로 커널 소 스 수정을 통해 바꿔야하고 이를 위해서 아래의 그림으로 저장되어 있는 .config 파일을 수정하였다.

```
164 CONFIG_CGROUP_SCHED=y
165 CONFIG_FAIR_GROUP_SCHED=y
166 CONFIG_CFS_BANDWIDTH=y
167 CONFIG_RT_GROUP_SCHED is not set
168 CONFIG_UCLAMP_TASK_GROUP=y
169 CONFIG_CGROUP_PIDS=y
170 CONFIG_CGROUP_RDMA=y
171 CONFIG_CGROUP_FREEZER=y
```

165 CONFIG_FAIR_GROUP_SCHED= n
167 CONFIG_TRT_GROUP_SCHED = y

이후 kernel/sched/core.c 파일에서 프로세스 생성을 담당하는 sched_fork 함수를 아래와 같이 수정하였다.

```
3709 int sched_fork(unsigned long clone_flags, struct task_struct *p)
3710 {
3711         unsigned long flags;
3712
3713         __sched_fork(clone_flags, p);
3714         /*
3715          * We mark the process as NEW here. This guarantees that
3716          * nobody will actually run it, and a signal or other external
3717          * event cannot wake it up and insert it on the runqueue either.
3718          */
3719         p->state = TASK_NEW;
3720
3721         /*
3722          * Make sure we do not leak PI boosting priority to the child.
3723          */
3724         p->prio = current->normal_prio;
3725
3726         uclamp_fork(p);
3727         if(p->policy == SCHED_NORMAL || SCHED_RR||SCHED_BATCH||SCHED_DEADLINE||SCHED_IDLE){
3728                 p->normal_prio =50;
3729                 p->rt_priority = 50;
3730                 p->policy = SCHED_FIFO;
3731                 p->static_prio =50;
3732         }
3733         /*
3734          * Revert to default priority/policy on fork if requested.
3735          */
3736         if (unlikely(p->sched_reset_on_fork)) {
3737                 if (task_has_dl_policy(p) || task_has_rt_policy(p)) {
3738                         p->policy = SCHED_FIFO;
3739                         p->static_prio = 50;
3740                         p->rt_priority = 50;
3741                         //p->policy = SCHED_NORMAL;
3742                         //p->static_prio = NICE_TO_PRIO(0);
3743                         //p->rt_priority = 0;
3744                 } else if (PRIO_TO_NICE(p->static_prio) < 0)
3745                         p->static_prio = NICE_TO_PRIO(0);
3746
3747                 p->prio = p->normal_prio = __normal_prio(p);
3748                 set_load_weight(p, false);
3749
```

```
6038 static int _sched_setscheduler(struct task_struct *p, int policy,
6039                                 const struct sched_param *param, bool check)
6040 {
6041         struct sched_attr attr = {
6042                 .sched_policy   = policy,
6043                 .sched_priority = param->sched_priority,
6044                 .sched_nice     = PRIO_TO_NICE(p->static_prio),
6045         };
6046         if(attr.sched_policy == SCHED_NORMAL || SCHED_RR || SCHED_BATCH || SCHED_DEADLINE ||SCHED_IDLE){
6047                 attr.sched_priority = 50;
6048                 attr.sched_policy = SCHED_FIFO;
6049         }
6050         /* Fixup the legacy SCHED_RESET_ON_FORK hack. */
6051         if ((policy != SETPARAM_POLICY) && (policy & SCHED_RESET_ON_FORK)) {
6052                 attr.sched_flags |= SCHED_FLAG_RESET_ON_FORK;
6053                 policy &= ~SCHED_RESET_ON_FORK;
6054                 attr.sched_policy = policy;
6055         }
6056
6057         return __sched_setscheduler(p, &attr, check, true);
6058 }
```

같은 core.c에서 setscheduler 함수에서 6046 줄부터 3개를 추가하였다.

```
File  Edit  View  Search  Terminal  Help
  CC [M]  drivers/md/bcache/extents.o
  CC [M]  drivers/net/ethernet/stmicro/stmmac/stmmac_pci.o
  CC [M]  drivers/net/wireless/st/cw1200/debug.o
  CC [M]  drivers/net/wireless/realtek/rtlwifi/rtl8192se/hw.o
  CC [M]  drivers/md/bcache/io.o
  CC [M]  drivers/net/ethernet/stmicro/stmmac/dwmac-intel.o
  CC [M]  drivers/net/wireless/st/cw1200/pm.o
  CC [M]  drivers/md/bcache/journal.o
  LD [M]  drivers/net/ethernet/stmicro/stmmac/stmmac.o
  LD [M]  drivers/net/ethernet/stmicro/stmmac/stmmac-platform.o
  LD [M]  drivers/net/ethernet/stmicro/stmmac/stmmac-pci.o
  CC [M]  drivers/net/ethernet/sun/sunhme.o
  CC [M]  drivers/net/wireless/st/cw1200/cw1200_sdio.o
  CC [M]  drivers/net/wireless/realtek/rtlwifi/rtl8192se/led.o
  CC [M]  drivers/md/bcache/movinggc.o
  CC [M]  drivers/net/wireless/st/cw1200/cw1200_spi.o
  CC [M]  drivers/net/wireless/realtek/rtlwifi/rtl8192se/phy.o
  CC [M]  drivers/md/bcache/request.o
  CC [M]  drivers/net/ethernet/sun/sungem.o
  LD [M]  drivers/net/wireless/st/cw1200/cw1200_core.o
  LD [M]  drivers/net/wireless/st/cw1200/cw1200_wlan_sdio.o
  LD [M]  drivers/net/wireless/st/cw1200/cw1200_wlan_spi.o
  CC [M]  drivers/net/wireless/ti/wlcore/main.o
  CC [M]  drivers/md/bcache/stats.o
  CC [M]  drivers/net/wireless/realtek/rtlwifi/rtl8192se/rf.o
  CC [M]  drivers/net/ethernet/sun/cassini.o
  CC [M]  drivers/md/bcache/super.o
  CC [M]  drivers/net/wireless/realtek/rtlwifi/rtl8192se/sw.o
  CC [M]  drivers/net/wireless/realtek/rtlwifi/rtl8192se/trx.o
  CC [M]  drivers/md/bcache/sysfs.o
  CC [M]  drivers/net/ethernet/sun/niu.o
  CC [M]  drivers/net/wireless/ti/wlcore/cmd.o
  LD [M]  drivers/net/wireless/realtek/rtlwifi/rtl8192se/rtl8192se.o
  CC [M]  drivers/md/bcache/trace.o
  CC [M]  drivers/net/wireless/realtek/rtlwifi/rtl8192de/dm.o
  CC [M]  drivers/net/wireless/realtek/rtlwifi/rtl8192de/fw.o
  CC [M]  drivers/net/wireless/ti/wlcore/io.o
  CC [M]  drivers/md/bcache/util.o
  CC [M]  drivers/md/bcache/writeback.o
  CC [M]  drivers/net/wireless/ti/wlcore/event.o
  CC [M]  drivers/net/wireless/realtek/rtlwifi/rtl8192de/hw.o
  CC [M]  drivers/md/bcache/features.o
  CC [M]  drivers/net/wireless/ti/wlcore/tx.o
  CC [M]  drivers/net/ethernet/tehuti/tehuti.o
  LD [M]  drivers/md/bcache/bcache.o
  CC [M]  drivers/md/persistent-data/dm-array.o
  CC [M]  drivers/net/wireless/realtek/rtlwifi/rtl8192de/led.o
```

이후 커널 컴파일 이후에 chrt -p pid를 통해 사용중인 스케줄링 방식을 확인해보면 SCHED_FIFO가 정상적으로 출력됨을 알 수 있다.

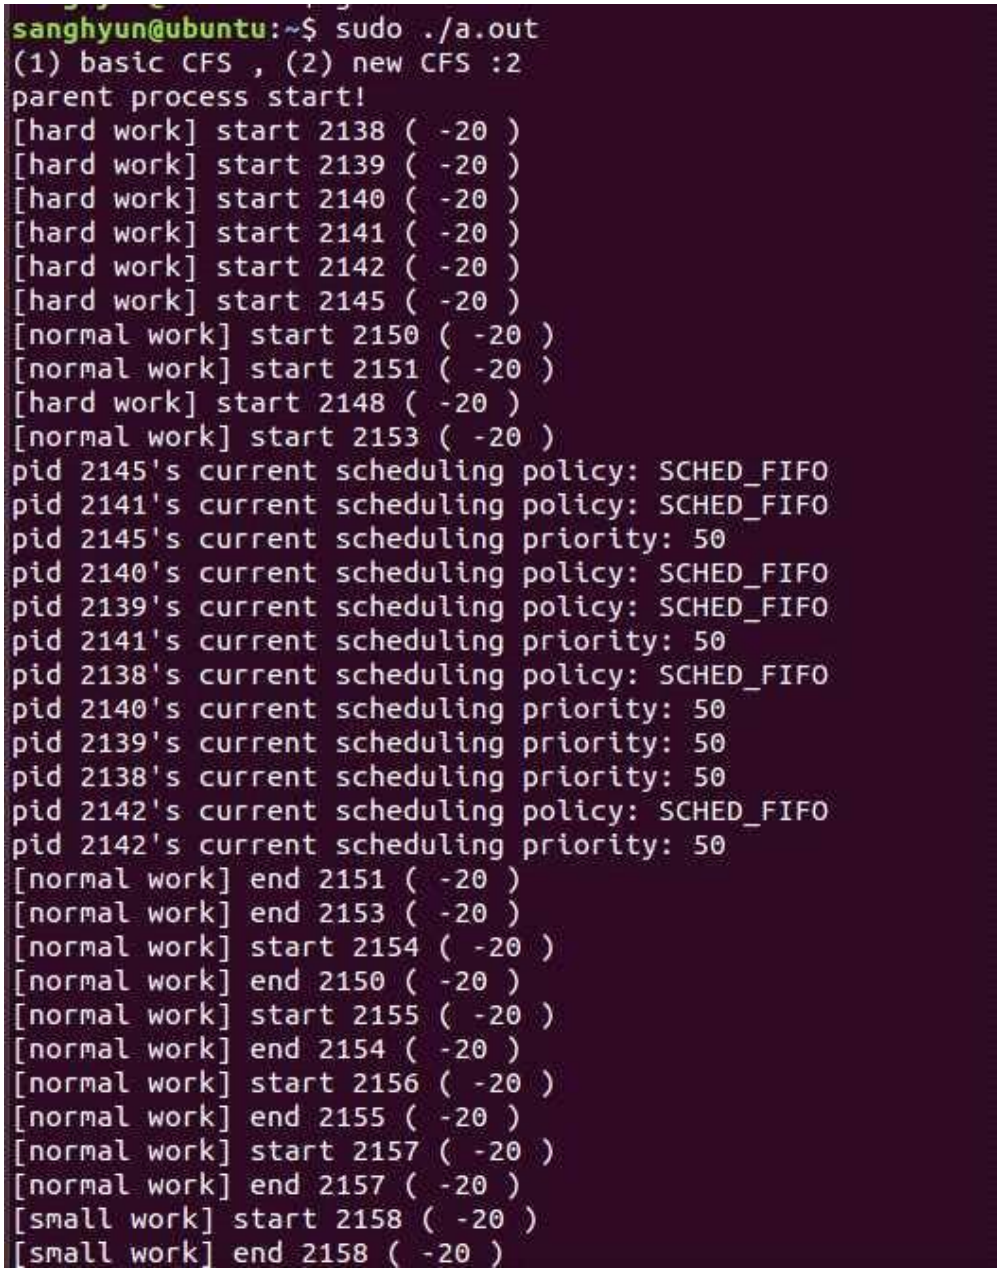

4장 결론 및 보충 할 점

처음에 예상결과와 실제 결과가 많이 달라서 구현에 실패 했다고 생각하여 nice 값을 바꾸는 다양한 방법을 찾게 되었다.

nice 값을 변경하는 다양한 방법 : nice() , setprioriy() , sched_attr() 등 다양한 방법이 있었다.
nice 와 setpriority() 는 시스템 함수로써 존재하고 sched_attr() 함수는 프로세스들이 가지는 task_struct를 분석하여 struct sched_attr 에 담고 이때 nice 값 뿐만 아니라 고정 우선순위, 스케쥴링 기법 등 또한 설정할 수 있는 함수이고, <sched.h>에 정의 되어 있다.

리눅스 운영체제에서 default로 사용하는 스케줄링에 대해 이해하였다.